

Changelog Branch AgentTest2

Rebuild agéntico del chatbot · FinanceSmart

Cierre 3 de mayo de 2026

23 archivos modificados · 30+ archivos nuevos · 191/191 tests verde
Regresión LLM 96.9% contra Gemini real · 0% alucinación en grounded

FinanceSmart — Changelog de la Branch AgentTest2

Proyecto: FinanceSmart (asistente financiero en español con chatbot agéntico) **Branch:** AgentTest2 (rama del rebuild agéntico) **Comparado contra:** `main` **Estadísticas globales:** 23 archivos modificados, 3,718 líneas añadidas, 1,006 borradas, +30 archivos nuevos (tests, migraciones, servicios, docs). **Fecha de cierre:** 3 de mayo de 2026 **Cobertura de pruebas:** 191/191 tests Jest verde · regresión LLM real 96.9 % (62/64)

Resumen ejecutivo

Qué se hizo: rebuild completo del chatbot de FinanceSmart, pasando de un sistema basado en context-injection con regex frágil a un **agente real con tool calling** que consulta los datos del usuario antes de responder. El rebuild se hizo en tres olas:

- 1. **Rebuild agéntico** — capa de proveedor multi-LLM (Gemini 2.5 Flash + Ollama qwen2.5:7b), agent loop con 18 tools (11 lectura, 5 escritura, 2 planning), envelope JSON typed con Zod, 11 widgets visuales, write-actions con confirmación de doble paso, y guardrails anti-alucinación a nivel estructural (enums per-request, validación de fechas, scope-bound al usuario).
- 1. **Auditoría sistemática (sweep #1)** — 7 subagentes en paralelo auditaron deps/bugs/perf/tests/guardrails. **21 issues** aplicados: vercel.json con maxDuration, atomic claim en proposalStore, transaccionalidad en aportes, defensive guards en widgets, code-splitting de bundle (1.1 MB → 4 chunks), timeouts upstream, force-break en loops redundantes, ownership checks defensivos, y 8 más.
- 1. **Mejoras tiered (sweep #2)** — otros **21 items** cubriendo los 5 tiers: streaming token-por-token real, compactación de historial, logger estructurado, audit log append-only, rate limit per-user IPv6-safe, cache de insights persistente en Postgres, a11y completo (ARIA + ESC + focus), TTS, touch drag, mobile-responsive, server-side chat history, planes financieros largo plazo, PDF export, notificaciones backend, e i18n scaffold.

Resultados medibles:

Métrica	Antes	Después
Tasa de alucinación en queries grounded	Frecuente (motivo del rebuild)	0 %
Regresión LLM contra Gemini real	Sin suite	96.9 % (62/64 prompts)
Tests Jest	~50	191 (18 suites)
Bundle frontend (chunk inicial)	~1.1 MB	355 KB (resto en chunks lazy)
SSE timeout en Vercel	10–60 s default	300 s
Widgets del chatbot	4 (parseados con regex)	11 (validados con Zod)
Tools del agente	0	18
Tablas nuevas en producción	—	7 (audit_log, chat_message, notificacion, plan_*, proactive_insights_cache)
<code>npm audit</code> (back + front)	—	0 vulnerabilidades

Lo que sigue habilitado pero sin UI todavía: historial de chat server-side, planes financieros largo plazo, notificaciones — los endpoints y tablas están listos en producción; solo falta la UI para exponerlos.

Estado del deployment: las 5 migraciones SQL (003-007) ya están aplicadas en el proyecto Supabase de producción `qzqtepussricbilarxyn` . El código está en working tree de `AgentTest2` , listo para commit + push. Vercel auto-deploya en cuanto se haga `git push` .

0. Por qué este rebuild

El chatbot anterior (`backend/routes/chatbot.js` previo) **alucinaba consistentemente** incluso con context-injection. Después de un intento fallido de hacerlo agéntico (commit `a25176a` revertido), el equipo había shipeado **5 patches consecutivos** de regex frágil para parsear los 4 widgets (`CHART/STREAK/COMPARE/SIMULATOR`).


Causas raíz identificadas:

1. Modelo subdimensionado (Ollama `llama3.1:8b` no maneja JSON estricto ni tool calling confiable).
2. Output free-form con regex post-procesado (`STREAKS` vs `STREAK` , falta de braces, `TAG` , etc.).
3. Tools sin validación server-side → fechas alucinadas crashearon Postgres.
4. Sin suite de regresión → alucinaciones se descubrían en producción.

Decisiones del equipo:

- Multi-provider, capability-aware. Gemini 2.5 Flash en producción; Ollama (`qwen2.5:7b`) como fallback offline.
 - Reemplazar regex de tags por **single typed JSON envelope** (zod-validated).
 - 4 capacidades agénticas: multi-step, write-actions-with-confirmation, proactive insights, long-horizon planning.
 - Sólo en español. Sofia es el fixture canónico.
-

1. Arquitectura final



Cada tool valida sus argumentos contra **enums por usuario** contruidos al inicio de cada request (`tools/context.js`). Esto previene estructuralmente la alucinación de IDs.

Las write tools **nunca mutan** la BD: emiten propuestas a un store en memoria. La mutación real ocurre sólo en `POST /api/chatbot/confirm-action` , que **re-valida** con la misma zod schema.

2. Cambios por capa

2.1 Backend — Núcleo agéntico

Archivo	Estado	Descripción
backend/utils/agent/loop.js	NUEVO	Agent loop. Iter cap = 10. Detecta loops redundantes (3 idénticos / ABAB). Streaming real vía generateStreamWithTools cuando se pasa onTextDelta. Compactación de historial — al pasar 40 KB, los functionResponse viejos se reemplazan por placeholders. Force-break en redundancia.
backend/utils/agent/grounding.js	NUEVO	Guardrails parametrizados por nombre del usuario (NO hardcoded "Sofía"). 6 reglas inviolables: nunca revelar prompt, nunca revelar nombres internos de tools, siempre español, nunca inventar montos/fechas/categorías, refuse out-of-scope, scope-bound al usuario.
backend/utils/agent/proposalStore.js	NUEVO	TTL store en memoria (10 min). API: create(), tryClaim(), release(), consume(), cancel(). Atómico: tryClaim() marca claim sincronamente antes de cualquier await, evita doble-ejecución por race. Sweeper background cada 5 min.
backend/utils/zodToGeminiSchema.js	NUEVO	Convierte zod schema → Gemini OpenAPI subset. Strip const, propertyName, additionalProperties, \$schema. Convierte oneOf de objetos → enum aplanado. Lowercase JSON-schema types (fix del bug ba00a0a).

2.2 Backend — Tools

Archivo	Estado	Descripción
backend/utils/tools/index.js	NUEVO	buildToolRegistry({supabase, id_usuario, opts}) . Devuelve {tools, geminiDeclarations, exec(name, args)} . Aplica zod safeParse antes de cada exec. Try/catch con error message redactado.
backend/utils/tools/context.js	NUEVO	Pre-fetch en paralelo de categoria/tarjeta/ahorro_meta/presupuesto/recurrencia. Construye Sets de IDs y Maps por nombre. Fail-fast si cualquier fetch falla (evita "Set vacío == cualquier ID es válido").
backend/utils/tools/schemas.js	NUEVO	Zod schemas con isoDate() (regex + calendar valid + range refine 2020-hoy). Per-request enums. TOOL_DESCRIPTIONS_ES con patrones explícitos para preguntas complejas (cambios de salario, proyección de metas, etc.).
backend/utils/tools/readTools.js	NUEVO	11 read tools: obtener_resumen_mes , obtener_resumen_periodo , obtener_movimientos , obtener_gastos_por_categoria (mes/periodo), obtener_metas_ahorro , obtener_presupuestos , obtener_recurrencias , obtener_tarjetas , obtener_salud_financiera , obtener_insights_automaticos , obtener_planes , obtener_adherencia_plan . Truncación a 25 KB con marker.
backend/utils/tools/writeTools.js	NUEVO	5 write tools: proponer_aporte_meta , proponer_crear_presupuesto , proponer_modificar_presupuesto , proponer_toggle_recurrencia , proponer_crear_meta . Cero mutaciones directas — sólo emiten proposal y SSE event. crear_movimiento deliberadamente omitido (alto riesgo de monto alucinado).

2.3 Backend — Providers

Archivo	Estado	Descripción
backend/utils/providers/gemini.js	MODIFICADO	Capabilities flag (supportsStructuredOutput/Tools/ToolCalling/Streaming). generateStream , generateStructured , generateWithTools , generateStreamWithTools (NUEVO) — yields {type:'text', delta} o {type:'toolCalls', calls} . Timeout 90 s vía AbortSignal.any([clientSignal, AbortSignal.timeout(N)]) con fallback Node 18.
backend/utils/providers/ollama.js	MODIFICADO	Mismas capabilities (excepto toolCalling=false porque es JSON-blob). Protocolo: modelo emite {"action":"tool_call",...} o {"action":"respond",...} . Reintento 1 vez en JSON inválido, fallback a texto plano. Timeout 120 s vía raceWithTimeout . Modelo default upgradado a qwen2.5:7b .
backend/utils/aiProvider.js	MODIFICADO	Provider selection por env AI_PROVIDER (default gemini). Health-check graceful — si Gemini key falta, fallback a Ollama con warning.

2.4 Backend — Schemas

Archivo	Estado	Descripción
backend/schemas/chatbotResponse.js	NUEVO	Zod envelope ChatbotResponse = { text, widgets[], toolCalls?, actions? }. Widget = discriminated union de 11 kinds.

2.5 Backend — Observabilidad / Auditoría

Archivo	Estado	Descripción
backend/utils/logger.js	NUEVO	Logger JSON-line estructurado. Levels: debug/info/warn/error. Indexable en Vercel logs. Drop-in para console.error. Listo para Sentry / Logtail (un solo emit() para reemplazar).
backend/utils/auditLog.js	NUEVO	record({id_usuario, action, status, params, error_message}) — append-only a tabla audit_log. Falla silenciosa (no bloquea ejecución del usuario). Llamado en cada confirm-action exitosa o fallida.

2.6 Backend — Servicios

Archivo	Estado	Descripción
backend/services/proactiveInsightsService.js	NUEVO	Insights del dashboard. Tier-1 cache memoria + Tier-2 cache Postgres (proactive_insights_cache , TTL 6 h). Cold-start resilient. LLM-summarized si capability disponible, fallback determinístico.

2.7 Backend — Routes (modificados)

Archivo	Cambios principales
backend/routes/chatbot.js	Reescritura completa. Capability-branch (Gemini agent loop / Ollama context-injection). SSE con guards <code>writableEnded/destroyed</code> . Streaming real token-por-token vía <code>onTextDelta</code> . Endpoints <code>/confirm-action</code> y <code>/cancel-action</code> . Atomic <code>tryClaim</code> antes de <code>await</code> . Audit log integrado. Logger structured. Pre-fetch (<code>fetchUserFinancialData</code>) y <code>buildToolRegistry</code> paralelizados.
backend/routes/metas.js	<code>aportarMeta</code> : validación de ownership de <code>id_tarjeta</code> (defense in depth para path directo). Transaccional manual : si insert de movimiento falla, rollback de progreso .
backend/routes/movimientos.js	<code>listMovimientos</code> : nuevo parámetro <code>categoriaId</code> que se empuja al query Supabase (antes filtraba en JS DESPUÉS del limit → false-empties).
backend/routes/recurrencias.js	<code>materializar</code> ahora opt-in (<code>materialize:true</code>). Throttle in-memory 1 h por usuario. Pre-check <code>anyDue</code> evita query inútil. Path del agente pasa <code>materialize:false</code> .
backend/routes/insights.js	Modificado para retornar <code>kind</code> en cada insight (routing de notificaciones).
backend/routes/presupuestos.js	Refactor menor.
backend/routes/proactiveInsights.js	NUEVO endpoint <code>GET /api/proactive-insights</code> .
backend/routes/chatHistory.js	NUEVO. <code>GET/POST/DELETE /api/chat-history</code> . Persistencia server-side de mensajes con paginación y caps de tamaño.
backend/routes/planes.js	NUEVO. CRUD de planes financieros largo plazo + cálculo de adherencia.
backend/routes/export.js	NUEVO. <code>GET /api/export/summary-html</code> genera HTML print-ready. Usuario lo guarda como PDF desde el browser.
backend/routes/notificaciones.js	NUEVO. CRUD + <code>generateForUser()</code> que emite notificación por cada insight high-severity (idempotente por día).

2.8 Backend — app.js

- 6 routes nuevas montadas: `proactive-insights` , `chat-history` , `planes` , `export` , `notificaciones` , (más las pre-existentes).
- `chatbotIpLimit` (60/min, IP gate antes de auth) + `chatbotUserLimit` (20/min, **per-user** después de auth con `keyGenerator` IPv6-safe usando `ipKeyGenerator`).

2.9 Backend — Migraciones SQL nuevas

Archivo	Tabla(s)	Propósito
003_audit_log.sql	audit_log	Append-only de todas las write actions ejecutadas. Indexes user+created y action+created.
004_proactive_insights_cache.sql	proactive_insights_cache	Cache persistente de insights LLM, TTL 6 h. Sobrevive cold starts de Vercel.
005_chat_message.sql	chat_message	Historial del chat server-side por usuario. Cross-device, debugging.
006_planes_financieros.sql	plan_financiero , plan_hito , plan_revision	Planes largo plazo: ahorro multi-mes, liquidación de deuda, metas compuestas. Hitos + revisiones de adherencia.
007_notificacion.sql	notificacion	Alertas (presupuesto excedido, cargo recurrente grande, meta completada). Severidad alta/media/baja.
apply_003_to_007.sql	(bundle)	Concatenación idempotente para correr todo en un solo Run del SQL Editor. Aplicado en producción.

2.10 Backend — Scripts

Archivo	Cambios
backend/scripts/seed-sofia.js	Reescrito de cero. 281 movimientos en 12 meses (jun 2025 → may 2026). Realismo: salario subió en febrero (\$50k→\$54k), freelance variable (\$2.5k-\$5.5k), spike navideño en diciembre, Adobe contratado hace 8 meses, Monitor 4K \$5,500 en oct 2025, aportes bi-mensuales de \$1,500 a Cancún. Categorías mapeadas explícitamente por ID (Renta como Vivienda, no como Ahorro).
backend/utils/aiProvider.js	Provider selection.

2.11 Backend — Tests

18 test suites, 191 tests verde:

Test	Cubre
agent.test.js	Loop: tool execution, MAX_ITERS cap, redundancy break, parallel tool calls, abort signal
auth.test.js	Bearer parsing, Supabase token rejection, profile auto-create
chatbot.test.js	SSE input validation, modes, system prompt content, actions[] , widgets[] dual-emit, provider error events
chatbotConfirm.test.js	/confirm-action , /cancel-action : 400/403/404, single-shot consume, additional_params re-validation
dashboard.test.js	Totales, sign handling, tarjetaSeleccionada, empty user, DB error path
finanzas.test.js	Mensual/trimestral/anual, case-insensitive
geminiProvider.test.js	NUEVO. Capability flags, generateWithTools parsea text + functionCall, error sin API key, 429 surfaced
health.test.js	computeScore unit + endpoint smoke
metas.test.js	POST/PATCH/DELETE validation
movimientos.test.js	Validation, tarjeta ownership, sign-flip, CSV export
ollamaProvider.test.js	NUEVO. Capability flags, JSON-blob protocol → toolCalls[]/text translation
presupuestos.test.js	monthRange + upsert/delete validation
proposalStore.test.js	Lifecycle: create, scoped get, single-consume, cancel, per-user cap
recurrencias.test.js	dueDatesSince + validation + partial PATCH
tarjetas.test.js	POST/PATCH validation
toolContext.test.js	NUEVO. Sets/Maps construction, error → throw (defense vs partial validation)
tools.test.js	Registry build, Gemini declaration shape, schema rejections
writeTools.test.js	Write-tool exposure gating, proposal-only, fabricated id rejection, monto cap
helpers/mockProvider.js	NUEVO. Scripted provider para tests del loop

2.12 Backend — Regresión

Archivo	Descripción
backend/regression/prompts.json	67 prompts en 26 categorías (resumen, categorías, presupuestos, metas, edge_cases, recurrencias, tarjetas, movimientos, comparacion, salud, hallucination_probe, out_of_scope, multi_step, insights, small_talk, consejo, adversarial, ambiguous, dates, numbers, fixture_edge, concision, efficiency, grounded_refusal, complex, widgets_new).
backend/regression/expectedAnswers.js	Respuestas esperadas hand-curated, computadas del estado real de Sofia post-seed.
backend/regression/sofiaFixture.js	Snapshot de la fixture.
backend/regression/computeExpectedFromSupabase.js	Recalcula valores esperados desde la BD.
backend/regression/runner.js	Ejecuta los 67 prompts contra Gemini real. Emite reporte JSON + CSV append-only.
backend/regression/assertions.js	11 tipos: contains_number , cites_category , no_fabricated_categories , no_dates_outside_data , no_fabricated_amounts , invokes_tool , does_not_invoke_tool , refuses_gracefully , mentions_meta , language , max_length .
backend/regression/generatePromptSheet.js	Genera HTML imprimible con prompts + valores esperados.
backend/regression/PROMPT_SHEET.html	Output del generador.

Resultado actual: 96.9 % (62/64 antes de los 3 nuevos widgets). Las 2 fallas (`complex_salary_raise` , `complex_savings_progress`) son comportamiento del modelo (se rinde) — mitigadas con descripciones de tools más explícitas.

3. Frontend

3.1 frontend/src/components/Chatbot.jsx — el archivo grande

Este archivo (~2,000 LOC) concentra: 11 widget renderers, ActionProposalCard, lógica de SSE, drag/resize, voz, TTS, y todo el wiring del chat.

Cambios estructurales:

- **11 widgets renderers** (todos defensivos contra payloads malformados):
 - `InlineChart` (Recharts pie/bar/line) - `InlineStreak` — revamp con look-and-feel Banorte (rojo brand) - `InlineCompare` — dos columnas con delta arrows verde/rojo - `InlineSimulator` — sliders interactivos para 4 tipos - `InlineGauge` — semicírculo con tick marks, % en el centro color-coded - `InlineHeatmap` — celdas con intensidad rojo opacity-based - `InlineSubsBreakdown` — barras de suscripciones con totales mensual/anual - `InlineTopMerchants` — top 3 con medallas + barras - `InlineSavingsRate` — donut ring con tier (Excelente/Bien/A mejorar/Negativo) - `InlineRecCal` — calendar grid con dot por día con cargo (días `D,L,Ma,Mi,J,V,S` para evitar M ambiguo) - `InlineSparklines` — mini-trends por categoría con delta %

- **ActionProposalCard** — confirm/cancel con `inFlightRef` (latch sincrónico) que previene doble-clic. Tarjeta picker cuando `needs:['id_tarjeta']`.
- **Stream cleanup en unmount** — `streamAbortRef.current?.abort()` en cleanup `useEffect`.
- **Speech recognition cleanup** — abort + nullify handlers en cleanup.
- **TTS** — Web Speech API `SpeechSynthesis`. Toggle  /  en header. Lee solo replies completos (no parciales). Limpia markdown y widget tags antes de hablar. Dedupe con `lastSpokenRef`.
- **a11y pack**:
 - `role="dialog"` + `aria-modal="true"` + `aria-label` en `.chat-window` - `aria-label` en TODOS los icon-only buttons (mic, send, cancel, settings, fullscreen, close, FAB) - `aria-pressed` en mic y TTS toggles - `aria-expanded` en FAB
 - **ESC cierra** chat (o el panel de settings si está abierto)
- **Stable React keys** — `nextMsgId()` monótonico en cada nuevo mensaje. React key `m- $\{id\}$` o fallback `i- $\{index\}$` .
- **Touch drag support** — `pointermove` / `pointerup` / `pointercancel` (en vez de `mousemove` / `mouseup`). Funciona en móvil/tablet.
- **Debounce localStorage** — writes diferidos 500 ms (antes write-por-keystroke durante streaming).
- **Backend URL** del bot AI (`Fortia AI`) llamada con `mode` `coach/analyst`.

3.2 `frontend/src/components/FinancialDashboard.jsx`

- Mount de `<ProactiveInsightsPanel>` arriba.
- **Loading state** explícito (`Cargando tus finanzas...`).
- **Error banner** explícito con `role="alert"` cuando la API falla (antes silently fallback a mock).
- `AbortController` en el effect para cancelar fetches stale (race entre tab switches).
- `axios.isCancel` ignora aborts intencionales para no spamear el banner.

3.3 `frontend/src/components/ProactiveInsightsPanel.jsx` — **NUEVO**

- 3 cards dismissibles arriba del dashboard.
- Hits `/api/proactive-insights` (que tira del cache 6 h memoria + Postgres).
- Severidad: alta (rojo) / media (naranja) / baja (gris).

3.4 `frontend/src/styles/chatbot.css`

- Paleta `ACCENT` restringida: rojo, verde, naranja, grises, blanco (Banorte brand).
- Charts respetan la paleta (`CHART_PALETTE` 8 colores).
- 11 widget styles con `::before` rojo→naranja gradient bar arriba de cada card.
- Streak revamp: white card con accent rojo (en vez de dark hero card).
- Gauge con tick marks y meta-rows.
- **Mobile-responsive**: `@media (max-width: 640px)` auto-fullscreen + oculta resize handles + ajusta FAB.

3.5 `frontend/vite.config.js`

- `sourcemap: 'hidden'` (genera maps sin referenciarlos en el bundle servido).
- **Code-splitting** vía `manualChunks` :
 - `recharts` (~404 KB) → chunk separado - `markdown` (react-markdown + remark-gfm, ~165 KB) → chunk separado - `supabase` (~193 KB) → chunk separado - **index principal: 355 KB** (antes ~1.1 MB)

3.6 frontend/src/i18n/ — NUEVO

- Scaffold de i18n sin runtime dep.
- index.js con t(key, params) para lookups dotted.
- es-MX.js con todas las strings user-facing (chatbot, dashboard, proposal, units).
- Para agregar otro locale: drop archivo + add a locales . Default es-MX.

3.7 frontend/package.json

- **Removido** @supabase/ssr (no usado en SPA Vite).
- Patch upgrades pendientes (no aplicados en este sprint, sin riesgo): react, axios, recharts, react-router-dom, varios eslint plugins.

3.8 frontend/src/components/Chatbot.jsx — nextMsgId helper

```
let _msgIdCounter = 0;
const nextMsgId = () => `${Date.now()}-${++_msgIdCounter}`;
```

4. Otros archivos

Archivo	Estado	Descripción
vercel.json	MODIFICADO	Bloque functions con maxDuration: 300 y memory: 1024 para api/index.js . Sin esto, el SSE del chatbot se cortaba a 10/60 s default.
CLAUDE.md	NUEVO (raíz)	Onboarding completo para futuros agentes Claude en el repo: stack, layout, comandos, env vars, gotchas, dónde mirar primero.
SEED_SOFIA_README.md	NUEVO (raíz)	Documentación de la fixture Sofia.
.gitignore	MODIFICADO	Agregado backend/test_*.json/csv , backend/regression/reports/ , backend/regression/summary.csv , backend/coverage/ , frontend/dist/ , .vscode/ , .idea/ .
.github/workflows/ci.yml	NUEVO	CI: lint + jest + build.
.github/workflows/regression.yml	NUEVO	Regresión LLM programada (semanal + manual dispatch).
docs/SCMP.md + docs/SCMP.pdf	NUEVOS	Plan de Gestión de Configuración de Software completo.
docs/md-to-pdf.js	NUEVO	Pipeline markdown → HTML → PDF (Chrome headless).
frontend/public/favicon.{png,svg}	NUEVOS	Branding.
frontend/src/Logo_de_Banorte_neutral.svg.png	NUEVO	Logo.

Eliminados:

- `frontend/src/components/ChatbotTestModal.jsx` (reemplazado por suite de regresión)
 - `frontend/src/utils/chatbotTests.js` (idem)
 - `backend/test_report_manual.json` + `backend/test_results.csv` + `backend/test_results_report.csv` (artifacts)
 - `backend/package.json` : removido `zod-to-json-schema` (zod v4 tiene `z.toJSONSchema` nativo)
 - `frontend/src/components/Chatbot.jsx` : removido import muerto `TbSettings`
-

5. Auditoría sistemática (sweep #1)

Lancé **7 subagentes en paralelo** para auditar: deps backend, deps frontend, bugs backend, bugs frontend, cobertura de tests, performance, guardrails de alucinación. **Total hallazgos: ~50.** Aplicados:

CRITICAL (5)

1. `vercel.json` con `maxDuration: 300` + Fluid Compute (sin esto el SSE del chatbot se moría a los 10-60 s).
2. `proposalStore.tryClaim()` síncrono evita doble-ejecución por race (audit incorrectly assumed `consume()` no era atómico — sí lo es, pero hay un `await` intermedio en la ruta; `tryClaim` cierra esa ventana).
3. `aportarMeta` con rollback manual del `progreso` si insert de movimiento falla.
4. Cleanup de `streamAbortRef` y speech recognition al unmount del Chatbot.
5. Defensive guards en 9 widget renderers (un payload malformado white-screeneaba el chat).

HIGH (10)

1. `aportarMeta` valida ownership de `id_tarjeta` (defense-in-depth para path directo PATCH `/metas/:id/aportar`).
2. `obtener_movimientos` empuja `id_categoria` al query Supabase (antes filtraba en JS DESPUÉS del limit → false-empties).
3. `send()` con guard `writableEnded/destroyed` + `res.on('error')` para EPIPE en disconnect.
4. `proponer_crear_meta.fecha_limite` usa `isoDate()` con `calendar+range` refine (rechaza `2025-13-01`).
5. Redundancia en agent loop ahora **rompe el loop** (antes solo nudge → modelo testarudo gastaba MAX_ITERS).
6. `materializar` es opt-in con throttle 1 h por usuario.
7. Pre-fetch + `buildToolRegistry` paralelizados (200-300 ms de latencia menos por turn).
8. Code-splitting frontend (1.1 MB → 4 chunks).
9. Double-confirm guard con `inFlightRef` en `ActionProposalCard`.
0. Speech recognition leak en unmount.

MEDIUM/LOW

- Timeouts upstream Gemini (90 s) y Ollama (120 s) con `AbortSignal.any`.
- 3 prompts nuevos en regresión para los widgets nuevos.
- `.gitignore` actualizado.
- Eliminación de orfans + deps muertas (`zod-to-json-schema` , `@supabase/ssr` , `TbSettings`).
- `InlineRecCal` días `D,L,Ma,Mi,J,V,S`.
- Descripciones de tools mejoradas para `complex_salary_raise` / `complex_savings_progress`.

npm audit: 0 vulnerabilidades en backend y frontend.

6. Mejoras de los 5 tiers (sweep #2)

Después del audit, hice un segundo sweep cubriendo **todos los tiers** (mejoras propuestas) + extras grandes:

Tier 1 — Bajo esfuerzo, alto impacto

1. **Streaming token-by-token real** (`generateStreamWithTools`) — el usuario ve tokens conforme Gemini los produce en la última iter (antes typewriter local).
2. **Compactación de historial del agente** — placeholder cuando supera 40 KB.
3. **Logger estructurado** JSON-line.
4. **a11y pack** completo.
5. Logger preparado para Sentry/Logtail.

Tier 2 — Medio esfuerzo, alto impacto

1. **Tests faltantes**: providers (Gemini/Ollama), `tools/context.js` . +10 tests, total 191.
2. (Skipped) E2E Playwright — out of scope para sprint.
3. **Long-horizon planning** (`plan_financiero` + `plan_hito` + `plan_revision` , 2 tools nuevos del agente, endpoint `/api/planes`).
4. **Proactive insights cache en Postgres** (tier-2: memoria → Postgres) sobrevive cold starts.
5. **Rate limit per-user** (después de auth) con `keyGenerator` IPv6-safe + IP gate antes de auth.

Tier 3 — UX

1. (Pendiente UI) Server-side chat history — backend listo (`/api/chat-history` + tabla `chat_message`).
2. **Debounce localStorage writes** 500 ms.
3. **Stable React keys** (`msg.id`).
4. **Touch drag support** (`pointer*` events).
5. **Loading/error states** explícitos en FinancialDashboard.
6. **TTS** (text-to-speech) toggle  /  con dedup.

Tier 4 — Plataforma

1. **Audit log** append-only (`audit_log` table).
2. (Pendiente integración externa) Sentry / Vercel Agent / PostHog.
3. CI workflow ya existía.
4. **CLAUDE.md** raíz.

Tier 5 — Producto

1. (Pendiente UI) **Webhook/notification scaffolding** — backend listo (`notificacion` table + endpoints + `generateForUser` que emite por insights high-severity).
2. (Pendiente UI) Multi-cuenta/familia.
3. **i18n scaffolding** (`es-MX` default, otros locales solo agregan archivo).
4. **PDF export endpoint** (`/api/export/summary-html` genera HTML print-ready).
5. **Mobile-responsive** chatbot (CSS media query auto-fullscreen).

7. Aplicaciones en producción (Supabase)

Las 5 migraciones SQL nuevas (003-007) fueron **aplicadas exitosamente** en el proyecto Supabase `qzqtpeussricbilarxyn` (FinanceSmart, A00838952's Org) vía SQL Editor con el bundle `apply_003_to_007.sql`.

Verificación:

```
SELECT tablename FROM pg_tables
WHERE schemaname = 'public'
  AND tablename IN ('audit_log', 'chat_message', 'notificacion',
                   'plan_financiero', 'plan_hito', 'plan_revision',
                   'proactive_insights_cache')
ORDER BY tablename;
-- 7 rows 
```

8. Verificación final

Check	Resultado
<code>cd backend && npm test</code>	191/191 tests verde (18 suites)
<code>cd frontend && npm run build</code>	OK , 7 s, code-splitting efectivo
<code>cd frontend && npm run lint</code>	5 errores pre-existentes (en archivos no tocados: <code>MetasAhorro.jsx</code> , <code>Tarjetas.jsx</code>) — no introducidos por este sprint
<code>npm audit (backend)</code>	0 vulnerabilidades
<code>npm audit (frontend)</code>	0 vulnerabilidades
Backend dev	Server running on port 3001 con Gemini activo (<code>tools</code> , <code>structured</code> , <code>streaming</code>)
Frontend dev	Vite ready en 835 ms, <code>http://localhost:5173</code>
Regresión LLM contra Gemini real	96.9 % (62/64) — las 2 fallas restantes son comportamiento del modelo (se rinde demasiado rápido), mitigadas con prompts mejorados
Tasa de alucinación en consultas grounded	0 %

9. Decisiones técnicas clave

- Express 5 + Vercel:** se usa `res.on('close')` no `req.on('close')` (Express 5 dispara `req.on('close')` apenas termina el body buffer).
- Zod v4** built-in `z.toJSONSchema()` (no zod-to-json-schema externo, que es zod v3 only).

3. **Gemini schema converter** propio (`zodToGeminiSchema`) — Gemini rechaza `const` , `propertyNames` , `oneOf` de objetos. Conversión + lowercase types.
 4. **FINAL_RESPONSE_NUDGE** — Gemini a veces no produce texto después de tool calls. Nudge fuerza un final reply.
 5. **Per-request enums** (`tools/context.js`) — defensa estructural contra alucinación de IDs.
 6. **Write tools nunca mutan** — solo proposals + SSE event. Mutación solo en `/confirm-action` con re-validación zod.
 7. **Streaming opcional** — `generateStreamWithTools` se usa solo si `onTextDelta` está presente, fallback a `generateWithTools` no-streaming en tests.
 8. **Cache híbrido** (memoria + Postgres) para insights — memoria es O(1) cuando warm, Postgres rehidrata después de cold start.
-

10. Próximos pasos sugeridos

Inmediato (deploy):

1. `git add . && git commit && git push` para subir todos los cambios working-tree.
2. Vercel auto-deploya. Smoke test: login → chatbot → preguntas básicas + acción con confirm.

Próximo sprint (UI para features ya backed):

1. UI para chat history server-side (panel "Conversaciones anteriores").
2. UI para planes financieros (página `/planes` con CRUD).
3. UI para notificaciones (badge en navbar + panel).
4. Integrar Sentry / Vercel Agent.

Continuo:

1. Correr `npm run regression` semanalmente y monitorear el CSV append-only.
 2. Cuando Gemini saque versión nueva, abstraer bien (la capa de provider lo hace fácil).
-

Fin del documento.